

Contexto

Las inundaciones constituyen uno de los desastres naturales más frecuentes y con mayor impacto social, económico y ambiental en muchas regiones del mundo. En Colombia, eventos recientes en departamentos como Córdoba han evidenciado la vulnerabilidad de comunidades asentadas en zonas cercanas a ríos y planicies de inundación, donde lluvias intensas pueden generar desbordamientos y afectar viviendas, infraestructura vial y áreas agrícolas. La disponibilidad de herramientas que permitan identificar de forma rápida y precisa las áreas inundadas es fundamental para apoyar la gestión del riesgo, la planificación territorial y la toma de decisiones durante emergencias.

En este contexto, las imágenes satelitales de radar de apertura sintética (SAR), como las proporcionadas por el satélite Sentinel-1, representan una fuente de información valiosa, ya que permiten observar la superficie terrestre incluso en condiciones de nubosidad o durante eventos de lluvia intensa, cuando otros sensores ópticos pueden presentar limitaciones. Gracias a estas características, las imágenes SAR han sido ampliamente utilizadas para la detección y monitoreo de cuerpos de agua y eventos de inundación.

El problema que se busca abordar en este proyecto es la identificación automática de áreas inundadas a partir de imágenes SAR, mediante técnicas de visión por computador y aprendizaje profundo. Específicamente, se plantea abordar el problema como una tarea de segmentación semántica, en la que el modelo clasifica cada píxel de la imagen como “agua de inundación” o “no inundado”, generando así una máscara espacial que represente la extensión del evento de inundación. Una vez obtenida esta máscara de inundación, será posible analizar la afectación potencial sobre infraestructura y usos del suelo, mediante la superposición espacial con capas geoespaciales externas, como redes de carreteras, edificaciones y mapas de cobertura del suelo. Este enfoque permitirá estimar, por ejemplo, qué áreas agrícolas, vías o zonas urbanas se encuentran dentro de las áreas inundadas.

El impacto esperado del proyecto consiste en desarrollar una metodología basada en inteligencia artificial que facilite el mapeo automático de inundaciones a partir de datos satelitales, contribuyendo al monitoreo de eventos extremos y proporcionando información útil para la gestión del riesgo y la planificación territorial.

Objetivos

Desarrollar un modelo de segmentación semántica basado en aprendizaje profundo que, utilizando imágenes SAR del satélite Sentinel-1, permita identificar y mapear automáticamente la extensión de áreas inundadas, generando máscaras de inundación que posteriormente puedan ser utilizadas para analizar su afectación potencial sobre infraestructura y usos del suelo mediante la integración con información geoespacial.

1. Recolectar y preparar un conjunto de datos de imágenes SAR provenientes del satélite Sentinel-1 junto con máscaras de inundación o datos de referencia que permitan el entrenamiento y validación del modelo.
2. Preprocesar las imágenes SAR mediante técnicas como normalización, filtrado de ruido y generación de sub-imágenes (tiles) para construir un dataset adecuado para tareas de segmentación.
3. Entrenar y evaluar un modelo de segmentación semántica que permita clasificar píxel a píxel las imágenes SAR en clases de agua de inundación y no inundado.
4. Analizar la afectación potencial de las inundaciones detectadas, mediante la superposición de las máscaras generadas por el modelo con capas geoespaciales de infraestructura y uso del suelo (como redes viales, edificaciones o coberturas del suelo).

Estado del arte

Históricamente, los primeros enfoques sistemáticos para la detección de inundaciones se basaron en la umbralización (thresholding) de la señal de retrodispersión en imágenes SAR, partiendo del supuesto de que las superficies lisas de agua devuelven poca energía al sensor. Aunque computacionalmente sencillos, estos métodos resultaban altamente sensibles al ruido speckle y a artefactos topográficos como sombras o reflexiones especulares generadas por el viento sobre el espejo de agua, lo que producía clasificaciones inconsistentes en terrenos con geometría compleja (Copernicus Data Space Ecosystem, 2024). Paralelamente, el auge de los sensores ópticos multiespectrales —como los embarcados en Sentinel-2— permitió el desarrollo de índices espectrales como el NDWI (Normalized Difference Water Index), cuya principal limitación es la incapacidad de penetrar la cobertura nubosa, condición que resulta especialmente crítica durante los eventos de lluvia intensa que desencadenan los desbordamientos en regiones como Córdoba.

Ante estas restricciones, investigadores recurrieron a algoritmos de aprendizaje automático clásico como Random Forest (RF) y Support Vector Machines (SVM) para integrar las polarizaciones VH y VV del satélite Sentinel-1. Si bien estos métodos mejoraron la precisión de la clasificación respecto a los enfoques de umbralización, su naturaleza píxel a píxel ignoraba el contexto espacial de los eventos de inundación, dificultando la delineación precisa de infraestructura crítica afectada (Li et al., 2024).

El estándar actual se centra en la segmentación semántica mediante redes neuronales convolucionales profundas. Arquitecturas del tipo U-Net han demostrado su capacidad para extraer características espaciales a múltiples escalas, clasificando regiones contextualizadas en lugar de píxeles aislados, lo que produce máscaras de inundación con mayor coherencia espacial y precisión para el análisis de daños (Li et al., 2024). De manera complementaria, la integración de datos SAR con series temporales de precipitación multisatélite —como los productos IMERG del programa GPM de la

NASA— ha permitido correlacionar la intensidad de la lluvia con la extensión del espejo de agua detectado, enriqueciendo la validación causal del evento (NASA Global Precipitation Measurement, 2025). La disponibilidad creciente de catálogos de datos históricos etiquetados, accesibles a través de plataformas como ArcGIS Living Atlas o repositorios como Floodcast en GitHub, ha facilitado el entrenamiento más robusto de estos modelos mediante validación cruzada con datos de múltiples regiones del mundo.

A pesar de los avances descritos, persisten desafíos técnicos relevantes en la detección automática de inundaciones con imágenes SAR. El efecto de doble rebote de la señal radar sobre estructuras verticales —como edificaciones o vegetación densa— genera respuestas de alta retrodispersión que pueden confundirse con superficies no inundadas, dificultando la clasificación en entornos urbanos o boscosos. Asimismo, la presencia de viento sobre el agua puede incrementar la rugosidad superficial y, con ello, la retrodispersión, lo que reduce la discriminabilidad entre agua y tierra. En contextos de inundaciones parciales bajo dosel vegetal, la señal SAR puede ser absorbida o dispersada por la vegetación antes de alcanzar la lámina de agua, subestimando la extensión real del evento. Estas limitaciones evidencian que la interpretación automática de imágenes SAR requiere estrategias robustas de preprocesamiento y modelos con capacidad de aprendizaje contextual, aspectos que han motivado la adopción progresiva de arquitecturas de aprendizaje profundo como marco de referencia en la disciplina.

Metodología de desarrollo y herramientas

El desarrollo del proyecto sigue una metodología iterativa organizada en cinco fases secuenciales. Todo el pipeline se implementa en Python.

Fase 1 — Recolección y exploración de datos. Descarga de imágenes Sentinel-1 (GRD, polarizaciones VV y VH) y sus máscaras de referencia. Análisis exploratorio de la distribución de clases y características de la señal SAR.

Fase 2 — Preprocesamiento. Aplicación de filtros para reducción de ruido speckle y generación de tiles con solapamiento para incrementar la variabilidad del conjunto de entrenamiento. Para esta etapa se emplean numpy para operaciones matriciales sobre los valores de retrodispersión, y scipy.ndimage junto con OpenCV (cv2) para la aplicación de filtros espaciales de reducción de ruido. Dado que el rendimiento de distintos filtros (Lee, Frost, mediana) puede variar según las características de la escena, esta fase contempla experimentación comparativa antes de fijar la configuración definitiva.

Fase 3 — Diseño y entrenamiento del modelo. Implementación de la arquitectura U-Net en PyTorch, con segmentation-models-pytorch para acceder a variantes como U-Net++ y backbones preentrenados (por ejemplo, ResNet). La función de pérdida combina Binary Cross-Entropy para gestionar el desbalance de clases, y el

entrenamiento se realiza con validación cruzada estratificada por evento de inundación. La aumentación de datos se gestiona con albumentations.

Fase 4 — Evaluación. Cálculo de métricas de segmentación (IoU, coeficiente Dice, precisión, recall y F1 por clase) sobre el conjunto de prueba, usando torchmetrics para el cómputo eficiente durante el entrenamiento y scikit-learn para la validación cruzada. El análisis cualitativo de los errores más frecuentes se apoya en visualizaciones con matplotlib y seaborn.

Fase 5 — Análisis geoespacial de impacto. Generación de máscaras de inundación para un evento de referencia y superposición con capas vectoriales de infraestructura y uso del suelo para cuantificar el área afectada por categoría.

Notebook de Aproximación Inicial

<https://colab.research.google.com/drive/1OAKQDk98xJMgd-rEUusdVk-hku6CK3Zi?usp=sharing>

Referencias Bibliográficas

- Chen, X., & Wang, J. (2023). *Multi-temporal Sentinel-1 analysis for flood monitoring in tropical regions*. Remote Sensing, 15(4), 1102. <https://doi.org/10.3390/rs15041102>
- Copernicus Data Space Ecosystem. (2024). *Sentinel-1 GRD User Guide and processing tutorials*. European Space Agency. <https://browser.dataspace.copernicus.eu/>
- IADSL Floodcast. (2023). *Global flood datasets for machine learning and contextual validation*. GitHub Pages. <https://iadsl.github.io/floodcast/data/>
- Li, Y., Zhang, R., & Liu, B. (2024). *Deep learning for SAR-based flood mapping: A review of current architectures and future directions*. IEEE Geoscience and Remote Sensing Magazine. <https://arxiv.org/abs/2304.10230>
- NASA Global Precipitation Measurement. (2025). *IMERG technical documentation: Integrated Multi-satellite Retrievals for GPM*. NASA. <https://gpm.nasa.gov/data/imerg>